





Análisis Exploratorio de Datos (EDA)

De la anatomía matemática a la responsabilidad ética.

No podemos modelar lo que no entendemos


El Análisis Exploratorio de Datos (EDA) es la auditoría clínica obligatoria. Interrogamos el dataset para revelar su estructura, detectar variables clave y limpiar anomalías antes de aplicar algoritmos de Machine Learning.



Saneamiento Base: El ruido matemático


Anomalía	Impacto en Machine Learning	Estrategia de Ingeniería
Valores Faltantes (NaN)	Invalida los cálculos algebraicos de la mayoría de los algoritmos.	Eliminación (<code>.dropna()</code>) si la pérdida es mínima ($< 5\%$) y aleatoria. Imputación (<code>.fillna()</code>) mediante media, mediana o moda.
Registros Duplicados	Genera overfitting (el algoritmo es obligado a memorizar registros repetidos en lugar de aprender el patrón general).	Detección (<code>.duplicated()</code>). Eliminación (<code>.drop_duplicates()</code>) preservando únicamente la primera (<code>keep='first'</code>) o última ocurrencia.

Mapeando la estructura del dato



Histogramas y Forma


- Agrupa variables numéricas continuas en intervalos contiguos (bins).
- Permite identificar de inmediato si existe una distribución normal (campana simétrica) o un sesgo pronunciado que desestabilice algoritmos como la Regresión Lineal.




Correlaciones Lineales

- La Matriz de Correlación calcula el Coeficiente de Pearson (-1 a +1) entre pares de variables.
- **El Objetivo: Detectar la Multicolinealidad** (variables predictoras altamente correlacionadas entre sí), lo que genera redundancia y desestabiliza modelos complejos.

Anatomía de la Distribución: El Diagrama de Caja



Aislamiento Estadístico (La Regla IQR)




El **Outlier (Atípico)**: Cualquier registro ubicado más allá de los límites matemáticos. Se representa como un punto aislado.

Formalmente etiquetado como anomalía matemática, exige una auditoría inmediata.

La Falsa Neutralidad del Algoritmo

En el desarrollo de Inteligencia Artificial, la calidad del dato trasciende la frontera del rendimiento técnico; es un imperativo ético y social.

Un modelo matemático carece de moral. No es neutral. Se limita a replicar y amplificar de forma automatizada las asimetrías, prejuicios o anomalías presentes en los datos históricos con los que fue entrenado.




El daño colateral del filtrado ciego

El **Peligro Automatizado**: Aplicar la eliminación sistemática de datos faltantes (NaN) o el filtrado drástico de registros atípicos (outliers) de manera descuidada suele borrar desproporcionadamente a grupos minoritarios o subrepresentados del dataset.


Impacto Operacional

Al purgar estos datos sin contexto de negocio, el modelo resultante se vuelve matemáticamente ciego ante perfiles reales.

Esto genera de forma directa **exclusión financiera, sesgos de contratación y discriminación algorítmica**.



La Responsabilidad del Ingeniero y el Principio de Equidad



La Decisión Humana

Es imperativo diseñar flujos de limpieza que diferencien con total precisión técnica entre:

(A) Un error de sistema: Ruido físico, fallas de captura o duplicados literales que deben limpiarse.

(B) Una realidad de negocio anómala pero legítima: Datos reales de poblaciones **minoritarias** que rompen la norma estadística pero deben protegerse.

“ Tu rol estratégico es auditar e interrogar la causa raíz de las anomalías antes de limpiar, garantizando que la automatización de decisiones no perpetúe injusticias sistémicas ocultas en la matriz de datos. ”

“Entender la anatomía matemática de tus datos es la única garantía de que tu modelo aprenda patrones reales en lugar de amplificar ruidos efímeros.”

Espacio para debate: Si un algoritmo discrimina a un usuario legítimo tras haber eliminado outliers de forma matemáticamente impecable (Regla IQR)...
¿De quién es la falla? ¿Del dato, de la matemática, o del ingeniero?