

Guía de Limpieza de Datos: Del Caos a la Inteligencia


DEL CAOS: Identificación de Problemas Comunes

Valores Faltantes y Duplicados




Datos vacíos (NaN) o registros repetidos que distorsionan el análisis estadístico.

Outliers y Ruido




Valores extremos fuera de rango o errores de digitación e inconsistencias de formato.

Impacto en el Modelo



Los datos sucios aumentan el error sistemático (sesgo) y la varianza en las predicciones.

PROCESAMIENTO




A LA INTELIGENCIA: Técnicas de Limpieza y Soluciones

Eliminación e Imputación




Borrar filas defectuosas o rellenar huecos usando la media, mediana o algoritmos (KNN).

Normalización y Estandarización



Escalar todos los valores a un rango adecuado para asegurar comparabilidad.

Automatización con Python



Uso de librerías como Pandas para ejecutar `'drop_duplicates()'` y `'fillna()'` eficientemente.

Comparativa de Acciones de Limpieza

Problema Detectado	Técnica de Limpieza	Resultado Esperado
Registros repetidos	Eliminación (<code>drop_duplicates()</code>)	Unicidad de los datos
Datos vacíos (NaN)	Imputación (media/mediana)	Dataset completo para análisis
Formatos distintos	Corrección manual o normalización	Consistencia y legibilidad